

VILNIAUS UNIVERSITETAS
INFORMATIKOS INSTITUTAS
PROGRAMŲ SISTEMŲ KATEDRA

**Mažos duomenų imties problemos poveikis
klasifikacijos tikslumui naudojant dirbtinius
neuroninius tinklus**

**The Effect of a Small Dataset Problem on Classification
Accuracy Using Artificial Neural Networks**

Bakalauro baigiamasis darbas

Atliko:	Miglė Vaitulevičiūtė	(parašas)
Darbo vadovas:	asist. dr. Vytautas Valaitis	(parašas)
Darbo recenzentas:	j. asist. Linas Petkevičius	(parašas)

Vilnius – 2019

Santrauka

Šį darbą sudaro teorinė ir eksperimentinė dalys. Teorinėje dalyje pirmiausia yra aprašomas dirbtinis neuroninis tinklas, jo sudėtis ir veikimas. Toliau yra apibrėžiami konvoliuciniai neuroniniai tinklai, jų sudėtis bei esamos architektūros. Taip pat yra apibrėžiamas AutoML ir architektūros paieškos algoritmas, kadangi eksperimentinėje dalyje yra naudojamas NASNet modelis. Šis modelis buvo pasirinktas dėl savo inovatoriškumo bei AutoML panaudojimo. Eksperimentinėje dalyje du NASNet modeliai (NASNet Large ir NASNet Mobile) yra suderinami su dviem skirtingais mažo kiekio duomenų rinkiniais bei keičiant mokomų sluoksnių kiekį. Naudojami du NASNet modeliai, nes jų gyliai skiriasi ir taip galima pamatyti kokią įtaką modelio gylis daro tikslumui bei papildomos metrikoms - atšaukimas ir precizija. Gauti bandymų rezultatai apdorojami ir lyginami, pateikiamos išvados. Per eksperimentą padarytos trys išvados - gilesnis modelis šio eksperimento metu pasirodė daug geriau negu kad negilus modelis, modelio mokymo duomenų rinkinio klasių sutapimas su derinimo duomenų rinkinio klasėmis nesuteikia daug geresnių rezultatų, per šį eksperimentą išbandytų mokomų sluoksnių skaičius parodė, jog didesnis mokomų sluoksnių skaičius derinimo metu pasiekia geresnius rezultatus.

Raktiniai žodžiai: NASNet, AutoML, derinimas, konvoliuciniai neuroniniai tinklai, neuroninės architektūros paieškos algoritmas, tikslumas, mažos duomenų imties problema

Summary

This work consists of theoretical and experimental parts. The theoretical part firstly describes the artificial neural network, its structure and functioning. Next, convolutional neural networks, their composition and existing architecture are defined. Also, the AutoML and architecture search algorithm are defined, as the NASNet model is used in the experimental part. This model has been chosen for its innovation and the use of AutoML. In the experimental part, two NASNet models (NASNet Large and NASNet Mobile) are fine-tuned with two different small datasets while changing the number of training layers. Two NASNet models are used, because they differ in depth and can be used to see the impact of model depth on accuracy. The obtained test results are processed and compared, and conclusions are given. In the experiment, three conclusions were made - the deeper model in this experiment proved to be much better than the shallow model, the overlap of the model training data set's classes with fine-tune data set's classes does not yield much better results, the tested amounts of trainable layers in the experiment showed that the higher the number of trainable layers in the model the better results are gotten.

Keywords: NASNet, AutoML, fine-tune, convolutional neural networks, neural architecture search algorithm, accuracy, small dataset problem

TURINYS

SANTRAUKA	2
SUMMARY	3
IVADAS	5
1. DIRBTINIS NEURONINIS TINKLAS	7
1.1. Dirbtinio neuroninio tinklo sudėtis	7
1.2. Dirbtinio neuroninio tinklo veikimas.....	7
1.3. Aktyvavimo funkcijos.....	8
1.4. Nuostolio funkcijos	9
1.5. Optimizavimo funkcijos	9
1.6. Hiperparametrai	11
2. KONVOLIUCINIS NEURONINIS TINKLAS	12
2.1. Konvoliucija	12
2.2. Konvoliucinio neuroninio tinklo sluoksniai.....	13
2.2.1. Konvoliucinis sluoksnis	13
2.2.2. Sujungimo sluoksnis	14
2.2.3. Pilno sujungimo sluoksnis	14
2.3. AutoML.....	14
2.4. Architektūros paieškos algoritmas	15
2.4.1. Paieškos erdvė	15
2.4.2. Paieškos strategija	16
2.4.3. Vykdyto vertinimo strategija	17
2.5. Architektūros	17
2.6. Modelio derinimas	19
2.7. Klaidų matrica.....	19
2.7.1. Tikslumas	20
2.7.2. Atšaukimas	20
2.7.3. Precizija.....	21
3. TECHNOLOGIJOS	22
3.1. ImageNet	22
3.2. Keras	22
3.3. TensorFlow	23
4. MODELIŲ DERINIMAS SU MAŽU DUOMENŲ RINKINIU	24
4.1. Tinklelio paieška	24
4.2. Programos veikimas.....	24
4.3. Modelių derinimas	25
4.3.1. Negilaus modelio derinimas	25
4.3.2. Gilaus modelio derinimas.....	28
REZULTATAI	32
IŠVADOS	33
LITERATŪRA	34
PRIEDAI	38
1 priedas. Tinklelio paieška	39
2 priedas. Modelio derinimo grafikai	42

Išvadas

Vienas iš dirbtinių neuroninių tinklų tipų yra konvoliuciniai neuroniniai tinklai, kurių viena iš sprendžiamų problemų yra klasifikacijos uždavinys [Fuk80; LHB⁺99]. Tai yra procesas, kurio metu yra ieškoma panašių požymių (angl. feature) tarp skirtingų objektų, pavyzdžiui, paveiksliukų, ir pagal tai jie yra skirstomi į atitinkamas klases [Pau01]. Klasifikacija yra labai aktuali, kadangi ji yra naudojama nuo medicinos iki savivaldžių automobilių.

Konvoliuciniai neuroniniai tinklai gali būti naudojami:

- Veido atpažinimui - identifikuoti arba verifikuoti asmenį. Pavyzdžiui, „DeepFace“ sistema sukurta „Facebook“ [TL14], kuri atpažįsta žmonių veidus nuotraukose, arba „Face ID“ sistema sukurta „Apple“, kuri yra skirta identifikuoti asmenį, kuris bando atrakinti telefoną.
- Medicinoje - širdies, plaučių, prostatos, krūties vėžių [GVR⁺10], akių ligų diagnozavimui [Gau15].
- Žmonių elgesio analizė realiu laiku – „DeepGlint“ nustato žmones nuotraukose ir nuspėja jų elgesį [BX16].
- Vertimas – „Google Translate“ gali versti tekstą iš paveiksliukų realiu laiku [Ras15].

Tam kad neuroninius tinklus būtų galima panaudoti kažkokioje sferoje reikia turėti neuroninių tinklų ekspertą bei tinkamai sužymėtą ir didelį duomenų rinkinį (angl. dataset). Mokslininkai ir komercinės įmonės neturinčios žinių neuroninių tinklų ar mašininio mokymosi srityse negali pasinaudoti jų teikiamais privalumais, nes egzistuoja per daug kintamųjų, pavyzdžiui, architektūros pasirinkimas, hiperparametrų optimizavimas, kurie lemia ar tinklas gerai atliks jam paskirtą užduotį [HKV19; LMH⁺19]. Taip pat visiems neuroniniams tinklams reikia didelio kiekio duomenų, kadangi jų tikslumas didėja logaritmiškai [CLS⁺15; SSS⁺17]. Tačiau realiaame pasaulyje duomenų kiekis ir žmogiškieji bei laiko resursai yra riboti, todėl yra siekiama keičiant dirbtinio tinklo architektūrą bei jo parametrus gauti kuo didesnę tikslumą. Tad, architektūros paieškos ir parametrų nustatymo automatizavimas turėtų leisti pigiau ir greičiau sukurti efektyvų bei tikslų neuroninį tinklą negu kad tai darant rankiniu būdu [RMS⁺17]. Tokiam procesui atlikti yra naudojamas automatizuotas mašininis mokymasis (angl. Automated Machine Learning (toliau - AutoML)).

2017 metais Google komanda naudodami AutoML sukūrė naują architektūrą NASNet [ZVS⁺17], kuri yra sudaryta iš dviejų tipų blokų, kurie yra sudėti vienas ant kito. Šiai architektūrai sukurti buvo naudojamas neuroninės architektūros paieškos (angl. neural architecture search) algoritmas. Jis automatiškai keisdamas vidinius parametrus ieško geriausios architektūros specifiniai duomenų imčiai. Taip pat NASNet modelio tikslumas yra 1,2% didesnis negu bet kokios kitos

žmogaus sukurtos architektūros [ZVS⁺17].

Bakalauro darbo tikslas yra palyginti skirtingų gylių NASNet modelių veikimą su mažu duomenų rinkiniu.

Uždaviniai:

1. Apžvelgti dirbtinių neuroninių tinklų ir konvoliucinių neuroninių tinklų sudėtį bei NAS algoritmo veikimą.
2. Rasti geriausius hiperparametrus skirtingų gylių modeliams su pasirinktu mažu duomenų rinkiniu.
3. Suderinti (angl. fine-tune) egzistuojančius skirtingų gylių modelius su pasirinktu mažu duomenų rinkiniu.
4. Palyginti ir įvertinti skirtingų gylių modelius pagal gautą derinimo informaciją.

1. Dirbtinis neuroninis tinklas

Pagal apibendrintą žmogaus smegenų veikimą buvo sugalvoti dirbtiniai neuroniniai tinklai [GBC16]. Bendrai žmogaus smegenys turi šimtus milijardų neuronų, kurie yra sujungti sinapsėmis. Per šiuos neuronus sklinda elektroniniai impulsai, perduodantys informaciją. Tokiu būdu žmonės gali atpažinti objektus, garsus ir t.t. Dirbtiniai neuroniniai tinklai veikia panašiai. Jie turi daug besijungiančių neuronų, kurie gauna informaciją ir pagal tą informaciją gali nuspręsti koks tai objektas. Tačiau ties tuo ir baigiasi žmogaus smegenų ir dirbtinių neuroninių tinklų panašumas, kadangi dirbtiniai neuroniniai tinklai yra matematinis algoritmas su aritmetiniais kintamaisiais. Šis algoritmas yra suvokiamas tik žmogui, kuris suprogramavo dirbtinį neuroninį tinklą, pačiam tinklui algoritmas nieko nereiškia, nuovokos nesuteikia.

1.1. Dirbtinio neuroninio tinklo sudėtis

Dirbtinis neuroninis tinklas yra sluoksnių rinkinys - neuronų grupė sudaro sluoksnį, kuris yra sujungtas tarpusavyje su kitais sluoksniais [ZGD03]. Vienas iš sluoksnių privalo būti įvesties sluoksnis, kuris atitinkamai pagal užduotį gali gauti įvairios formos informaciją - paveikslukai, vaizdo medžiaga, garsas ir t.t. Ši informacija yra reikalinga tam, kad tinklas galėtų ją išanalizuoti ir išmokyti, kad vėliau gavęs panašią informaciją galėtų ją atpažinti - tam reikalingas išvesties sluoksnis. Jis yra priešingame dirbtinio neuroninio tinklo gale negu įvesties sluoksnis. Tarp anksčiau apibūdintų sluoksnių yra įvairaus dydžio vidinė sluoksnių sistema, kuri atlieka pagrindinį darbą.

1.2. Dirbtinio neuroninio tinklo veikimas

Jungtys tarp neuronų yra pateiktos skaitine išraiška ir vadinamos svoriu. Kuo didesnis šis svoris tuo didesnę įtaką turi vienas neuronas kitam. Vienam neuronui yra pateikiama visų prieš jį buvusių neuronų informacija ir jungčių svoriai. Kiekvieno neurono informacija yra sudauginama su jo svoriu ir visi šie duomenys yra sudedami tarpusavyje bei pridedama slenksčio reikšmė (angl. bias). Taip iš vektoriaus gaunamas vienas rezultatas ir jei šis rezultatas tinka aktyvavimo funkcijai, jis yra perduodamas tolimesniems neuronams [Shi12]. Tokio tipo veikimo projektavimas yra vadinamas tiesioginio sklidimo (angl. feedforward) tinklu.

Tačiau jungčių svoriai nėra pastovūs. Kai dirbtinis neuroninis tinklas mokosi, galutinis rezultatas yra lyginamas su tikėtinu teisingu rezultatu (daugiau informacijos „Nuostolio funkcija“), jei šie rezultatai skiriasi, slenksčio reikšmės ir svoriai yra keičiami atitinkamai [RS17], tai vadina-

ma sklaidimo atgal algoritmu (angl. backpropagation). Mokymo metu duomenys neuroniniu tinklu keliauja į priekį - nuo įvesties į išvesties sluoksnį. Kai išvesties sluoksnis yra pasiekiamas, gautas rezultatas yra palyginamas su norimu rezultatu bei apskaičiuojama nuostolio funkcija - kaip stipriai skiriasi gautas ir norimas rezultatai. Pagal šią reikšmę matoma, kaip reiktų keisti gautą rezultatą, kad nuostolio funkcijos reikšmė pasiektų lokalų minimumą. Tačiau siekiant aukštesnio tikslumo reikia keisti viso neuroninio tinklo parametrus - svorius, slenksčio reikšmes. Taigi, iš išvesties rezultatų galima matyti, kaip reikia pakeisti - didinti arba mažinti - prieš tai buvusio sluoksnio parametrus, kad būtų gautas geriausias tikslumas. Šis procesas yra iteratyviai kartojamas kiekvienam neuronui su prieš jį einančiu sluoksniu bei jį galima įvardinti kaip funkciją (1):

$$\frac{\partial C_0}{\partial w^L} = \frac{\partial z^L}{\partial w^L} \frac{\partial a^L}{\partial z^L} \frac{\partial C_0}{\partial a^L}. \quad (1)$$

Šioje funkcijoje vienas sluoksnis turi vieną neuroną, priklausomai nuo neuronų ir sluoksnių skaičiaus prie funkcijos parametrų prisidėtų atitinkami indeksai. Funkcija parodo dalinės nuostolio funkcijos išvestinės ir dalinės svorio (arba slenksčio reikšmės) išvestinės santykį, kur w^L yra svoris, kurį galima pakeisti į b^L (slenksčio reikšmė), C_0 yra nuostolio funkcijos reikšmė, $z^L = w^L a^{L-1} + b^L$ ir $a^L = \sigma(z^L)$. Šitos funkcijos tikslas yra nustatyti kokį efektą svorio reikšmės pakeitimai turės nuostolio funkcijos reikšmei.

1.3. Aktyvavimo funkcijos

Aktyvavimo funkcijų (angl. activation function) yra įvairių, todėl specifinės problemos gali reikalauti vienos ar daugiau konkrečių aktyvavimo funkcijų [VK11]. Aktyvavimo funkcija yra skirta tam, kad nustatyti ar neuronui reikia būti aktyvuotam ar ne. Tai yra nusprendžiama pagal duomenis, kuriuos neuronas gauna, jeigu jie yra aktualūs, neuronas yra aktyvuojamas, jeigu ne - ignoruojamas. Šią funkciją galima aprašyti žemiau pateikta formule (2):

$$Y = A(\Sigma(w * d) + b). \quad (2)$$

Formulėje (2) pateikta raidė A reiškia bet kokią pasirinktą aktyvavimo funkciją, o jos parametrai - w yra svoris, d yra įvesties duomenys ir b yra slenksčio reikšmė. Taigi, ar neuronas bus aktyvuotas priklauso nuo prieš jį buvusio sluoksnio jungčių dydžio, kurios parodo kiek svarbi yra jungtis tarp neuronų, kadangi kuo didesnis svoris tuo didesnis rezultatas gaunamas svorį sudauginus su įvesties duomenimis. Taip pat slenksčio reikšmė parodo ar reikia sustiprinti ar susiplinti

gaunamą rezultatą. Y reikšmė priklauso nuo pasirinktos aktyvavimo funkcijos išvesties intervalo. Žemiau yra pateiktos kelios aktyvavimo funkcijos su išvesties intervalais.

Kelios aktyvavimo funkcijos:

- Sigmoidinė (angl. sigmoid function) - išvesties intervale $[0; 1]$.
- Hiperbolinio tangento (angl. hyperbolic tangent) - išvesties intervale $[-1; 1]$.
- Minkštojo maksimumo (angl. softmax function) - sunormuoja išvesties vektorių į 1.
- ReLU - išvesties intervale $[0; \text{begalybė}]$.

1.4. Nuostolio funkcijos

Mokantis dirbtiniam neuroniniam tinklui jo gaunami rezultatai gali labai skirtis nuo tikėtinų rezultatų, todėl nuostolio funkcija apskaičiuoja kaip stipriai skiriasi gautas rezultatas nuo tikėtino. Kuo didesnis nuostolis tuo toliau nuo teisingo atsakymo yra dirbtinis neuroninis tinklas [Dav15]. Paprasčiausia ir dažniausiai naudojama nuostolio funkcija yra vidutinio kvadratinio nukrypčio (angl. mean squared error). Ši funkcija apskaičiuoja kvadratinį skirtumą tarp tikėtino ir gauto rezultatų. Tačiau šios funkcijos vienas iš didesnių trūkumų - neproporcingas išskyrimas didelių rezultatų. Kadangi funkcija didėja kvadratiškai, o ne tiesiškai, tai gaunamas rezultatas tolsta nuo tikėtino rezultato.

Priklausomai nuo sprendžiamos problemos yra naudojamos skirtingos funkcijos. Viena iš problemų yra klasifikacijos - dažniausiai išvesties rezultatas yra tikimybės vertė $f(x)$. Bendrai, funkcijos reikšmės dydis parodo gauto rezultato tikslumą.

Kelios klasifikacijos nuostolio funkcijos:

- Binarinė kryžiaus entropija (angl. binary cross entropy).
- Neigiama registravimo tikimybė (angl. negative log likelihood).
- Maržos klasifikatorius (angl. margin classifier).
- Minkštų maržų klasifikatorius (angl. soft margin classifier).

1.5. Optimizavimo funkcijos

Optimizavimo funkcijos naudojamos vidinių tinklo parametrų atnaujinimui, kad sumažinti gaunamų rezultatų netikslumą [Nik16]. Visos optimizavimo funkcijos gali būti suskirstytos į du tipus - nuolatinio mokymosi greičio ir prisitaikančio mokymosi. Lentelė 1 buvo parengta remiantis [Rud16] straipsniu. Joje išvardintos visos populiariausios optimizavimo funkcijos.

1 lentelė. Optimizavimo funkcijos

Pavadinimas	Tipas	Privalumai	Trūkumai	Veikimas
SGD	Nuolatinio mokymosi greičio	Parametrų atnaujinimai turi aukštą dispersiją, kas leidžia lengviau rasti lokalų minimumą.	Didelis svyravimas trukdo konverguoti.	Parametrų atnaujinimas vykdomas kiekvienai mokymo iteracijai.
Adam	Prisitaikančio mokymosi	Greitai konverguoja ir modelio mokymosi greitis yra didelis bei efektyvus.	Praleidžia mažą lokalų minimumą.	Suskaičiuoja mokymosi greitį kiekvienam parametrai bei saugo eksponentiškai nykstantį prieš tai buvusį kvadratinio gradiento vidurkį ir eksponentiškai mažėjantį prieš tai buvusį gradiento vidurkį, panašų į pagreitį (angl. momentum).
Adagrad	Prisitaikančio mokymosi	Nereikia rankiniu būdu derinti mokymosi greičio.	Mokymosi greitis visada yra mažėjantis ir nykstantis, kas lėtina konvergavimą.	Leidžia mokymosi greičiui priklausyti nuo parametrų. Dideli atnaujinimai nedažniems parametrams, maži atnaujinimai dažniems parametrams.
RMSprop	Prisitaikančio mokymosi	Greitai konverguoja.	Pagreitis nedidina funkcijos efektyvumo.	Dalija mokymosi greitį iš eksponentiškai nykstančio kvadratinio gradiento vidurkio.

Skyriuje „Dirbtinio neuroninio tinklo veikimas“ minėta, kad sklidimo atgal algoritmas pagal

gauto ir norimo rezultatų skirtumą keičia vidinius neuroninio tinklo parametrus. Vidinių parametrų atnaujinimui yra naudojama optimizavimo funkcija, kuri apskaičiuoja gradientą. Svoriai yra keičiami pagal priešingą apskaičiuoto gradiento kryptį - bandoma leisti į gradiento minimumą.

Optimizavimo funkcijos turi parametą - mokymosi greitį (angl. learning rate). Jis privalo būti nustatytas, tačiau pasirinkti tinkamą mokymosi greitį gali būti sudėtinga - pasirinkus per mažą vidiniai parametrai gali labai lėtai konverguoti, o pasirinkus per didelį - parametrams gali trukdyti konverguoti ir priversti nuostolio funkciją svyruoti apie minimumą arba diverguoti [Leo98]. Optimizavimo funkcijos tikslas yra surasti lokalų minimumą, o to pasiekti galima gradientu judant į žemiausią jo vietą, tačiau pasirinkus per didelį mokymosi greitį yra galimybė, kad žemiausia vieta bus peršokta ir bus tolstama nuo jos.

1.6. Hiperparametrai

Mašiniame mokymesi terminas hiperparametras (angl. hyperparameter) yra naudojamas atskirti parametrus, kurie nėra išmokstami iš duomenų, kurie yra naudojami mokant modelį. Hiperparametrai apima kintamuosius skirtus reguliuoti neuroninį tinklą. Jie turi labai didelį poveikį neuroninio tinklo tikslumui, tačiau pasirinkti jų vertes gali būti sudėtinga, nes įtaką daro architektūra, duomenų rinkinys. Optimalių hiperparametrų radimui yra sugalvota daug metodų, kurie yra aprašyti „Paieškos strategija“ skyriuje. Dalis hiperparametrų yra: mokymosi greitis, epochų ir partijų (angl. batch) dydžiai, vidinių sluoksnių kiekis, išmetimo sluoksnio reikšmė, aktyvacijos, optimizacijos ir nuostolio funkcijos.

2. Konvoliucinis neuroninis tinklas

Konvoliuciniai neuroniniai tinklai yra labai panašūs į paprastus dirbtinius neuroninius tinklus (daugiau informacijos skyriuje „Dirbtinis neuroninis tinklas“). Tačiau pagrindinis skirtumas tarp šių tinklų yra, kad konvoliucinio neuroninio tinklo įvesties sluoksnius priima duomenis, kurie gali būti konvertuojami į 2D matricą, pavyzdžiui, paveikslukai, kurie jei padaryti su standartine skaitmenine kamera, turi tris komponentus - raudoną, žalią ir mėlyną. Šiuos komponentus galima įsivaizduoti kaip tris 2D matricas sudėtas viena ant kitos. Kiekvienos matricos i -osios eilutės ir j -ojo stulpelio elementas atitinka nuotraukos pikselį, kurio reikšmė yra intervale nuo 0 iki 255. Kadangi naudojamos informacijos tipas yra specifinis, tai labai sumažina tinklo parametrų kiekį ir tinklą padaro efektyvesnį [YK18].


Objektų atpažinimas paveikslukuose yra sudėtingas dėl šių iššūkių:

- Segmentavimas - paveikslukai gali atvaizduoti įvairias scenas, kuriose gali būti pavaizduota daug objektų, kurie vienas kita gali dalinai uždengti.
- Šviesa - pikselių intensyvumas gali būti paveiktas šviesos šaltinio ar pačio objekto.
- Deformacija - objektai gali būti deformuoti įvairiais būdais, pavyzdžiui, žmogaus ranka parašyti skaičiai.
- Galimybės - objektų klasės dažnai nustatomos pagal tai kaip patys objektai yra naudojami, pavyzdžiui, kėdės yra objektai sukurti sėdėti, tačiau jos gali turėti skirtingus dizainus.
- Žvilgsnio taškas - keičiant vietą iš kurios yra žiūrima gali keistis objekto forma, informacija šokinėja per įvesties sluoksnio dimensiją (t.y. pikselius).

2.1. Konvoliucija

Konvoliucija yra matematinė operacija, kuri apibūdina taisyklę, kuri parodo kaip reikia sujungti du informacijos rinkinius [PG17].

Pagal paveiksluką (1 pav.) matyti, kad įvesties duomenys ir filtras, kuris yra sudarytas iš svorių, yra pateikti 2D matricomis. Filtras juda nuo įvesties duomenų matricos kairės viršutinės dalies į dešinę, tada yra nuleidžiamas žemiau per vieną eilutę ir taip filtras juda per visą duomenų matricą, kol su visais jos duomenimis filtras yra sudauginamas ir užpildo naują matricą, kuri yra vadinama požymių planu (angl. feature map). Tačiau konvoliuciniai tinklai turi daug filtrų, kurie pereina per vieną paveiksluką, kiekvienas išskirdamas skirtingą paveiksluko požymį [Epp17]. Pirmuose sluoksniuose šiuos filtrus galima apibūdinti kaip horizontalių, vertikalinių ar įstrižių linijų filtrus, kurie sukuria paveikslėlio kraštų planą.



1 pav. Konvoliucijos veikimas

2.2. Konvoliucinio neuroninio tinklo sluoksniai

Konvoliuciniai neuroniniai tinklai tai yra sluoksnių rinkinys, kuris turi įvesties, vidinius ir išvesties sluoksnius. Tačiau vidiniai sluoksniai gali skirtis priklausomai nuo konvoliucinio neuroninio tinklo tipo. Konvoliuciniai neuroniniai tinklai turi tris pagrindinius sluoksnių tipus, kurie sudaro vidinį sluoksnį. Šie tipai yra konvoliucinis, sujungimo ir pilno sujungimo sluoksniai [RPA⁺18].

Nepagrindinių sluoksnių paaiškinimai:

- Plokštinimo sluoksnis (angl. flatten layer) - skirtas tam, kad įeinančius duomenis suploti į atitinkamą sluoksnių skaičių, jeigu sluoksnio parametras nenustatytas suplojama į vieną sluoksnį.
- Išmetimo sluoksnis (angl. dropout layer) - sluoksnyje atsitiktinai yra išjungiami tam tikri neuronai su Bernulio pasiskirstymo tikimybe, kuri priima dvi reikšmes 1 (sėkmė) ir 0 (nė sėkmė) bei šių reikšmių tikimybe p ir $1 - p$. Dažniausiai yra nustatytas 50 procentų.

2.2.1. Konvoliucinis sluoksnis

Konvoliucinis sluoksnis (angl. convolutional layer) yra pagrindinis konvoliucinio neuroninio tinklo sluoksnis, kuris nustato visus paveiksluko požymius. Kadangi įvesties informacija (paveikslukas) yra didelės dimensijos, neefektyvu visų neuronų sujungti vienus su kitais, todėl neuronai yra sujungiami su lokaliu informacijos kiekiu, kuris yra lygus filtro dydžiui ir vadinamas erdvinio mastu (angl. receptive field) [Li15].

Neuronų kiekis po konvoliucijos (požymių plano dydis) yra nustatomas trimis parametrais:

- Gylis (angl. depth) - atitinka filtrų skaičių.

- Žingsnis (angl. stride) - pikselių kiekis, kuris parodo per kiek reikia slinkti filtro matrica per įvesties informacijos matricą.
- Nulių pamušalas (angl. zero-padding) - įvesties informacijos matricos kraštus užpildyti nuliais.

2.2.2. Sujungimo sluoksnis

Periodiškai sujungimo sluoksnis (angl. pooling layer) yra įterpiamas tarp konvoliucinių. Pagrindinis sluoksnio tikslas yra laipsniškai mažinti erdvinį filtruojamo paveiksluko mastą. Šis veiksmas yra atliekamas tam, kad sumažinti parametrų ir skaičiavimų kiekį. Maksimumo sujungimo (angl. max pooling) sluoksnis, nepriklausomai nuo kiekvieno sluoksnio gylio, yra erdviškai (ilgis ir plotis) keičiamas ir rezultatas gaunamas naudojant MAX operaciją [LGT18]. Dažnai šis sluoksnis yra naudojamas su 2x2 dydžio filtru - įvesties duomenys yra suskaidomi į keturias lygias dalis ir iš kiekvienos dalies paimama didžiausia tos dalies reikšmė, iš kurių sudaroma nauja matrica. Egzistuoja ne tik maksimumo sujungimo sluoksniai, bet ir vidurkio sujungimo (angl. average pooling) - jame yra randama ne didžiausia matricos dalies reikšmė, o suskaičiuojamas vidurkis.

2.2.3. Pilno sujungimo sluoksnis

Pilno sujungimo sluoksnis (angl. fully connected layer) yra sujungtas su visais neuronais iš sluoksnio buvusio prieš jį. Šio sluoksnio tikslas yra panaudojant požymius, kurie buvo gauti iš prieš tai buvusių sluoksnių, nustatyti kokioms klasėms priklauso įvesties paveikslukas pagal mokymo informacijos imtį, kai neuroninio tinklo problema yra klasifikacija [Sin18]. Šiam sluoksniui yra priskiriama aktyvacijos funkcija, kuri neprivalo būti tokia pati kaip vidiniuose sluoksniuose naudota aktyvacijos funkcija.

2.3. AutoML

Automatizuotas mašininis mokymasis (angl. automated machine learning) siekia pilnai automatizuoti mašininio mokymosi pritaikymą realaus pasaulio problemoms spręsti. Siekiamybė yra kad vartotojui tereiks pateikti duomenų rinkinį ir AutoML sistema automatiškai nustatys koks būdas yra tinkamiausias. AutoML gali pagerinti našumą ir sutaupyti didelį kiekį laiko ir pinigų, nes nereikės samdyti mašininio mokymo ekspertų [HKV19].

AutoML tobulinimui spartinti yra rengiamas konkursas - ChaLearn AutoML, kuris pirmą kartą buvo surengtas 2014 metais. Konkursas susideda iš kelių etapų - kodo pateikimo, jo vertinimo

(validavimo) su viešais duomenų rinkiniais ir atsiliepimų gavimo bei kodo modifikavimo, o paskutiniame (finaliniame) etape paskutinis kodo pateikimas yra patikrinamas su penkiais skirtingais privačiais duomenų rinkiniais. Pagal gautus rezultatus dalyviai yra reitinguojami.

2.4. Architektūros paieškos algoritmas

Neuroninės architektūros paieškos (angl. neural architecture search (toliau - NAS)) algoritmas ieško geriausios neuroninio tinklo architektūros naudodamas specifinį duomenų rinkinį [WZL⁺19]. NAS gali būti matomas, kaip kad AutoML polaukis [HKV19]. NAS metodai yra kategorizuojami pagal tris dimensijas: paieškos erdvę (angl. search space), paieškos strategiją (angl. search strategy) ir įvykdymo vertinimo strategiją (angl. performance estimation strategy) [EMH18].

2.4.1. Paieškos erdvė

Paieškos erdvė apibrėžia kokia architektūra gali būti sukurta panaudojant žinias apie būdingas savybes esamų architektūrų, kurios yra tinkamos panašiai užduočiai spręsti. Tai gali stipriai sumažinti paieškos erdvės dydį ir supaprastinti pačią paiešką. Tačiau pradinių savybių nustatymas priklauso nuo žmogiškumo faktoriaus, kuris gali neleisti atrasti naujų architektūros sudedamųjų blokų. Dažniausios paieškos erdvės:

- Grandinės struktūros neuroninio tinklo (angl. chain-structured neural network) - gali būti aprašyta kaip n sluoksnių seka, kur i -tasis sluoksnis L_i gauna duomenis iš $i - 1$ sluoksnio ir juos toliau siunčia $i + 1$ sluoksniui. Pati erdvė yra parametrizuota pagal maksimalų sluoksnių skaičių, operacijos tipą, kurią vykdo kiekvienas sluoksnis, ir hiperparametrus, kurie susiję su sluoksnių operacijomis.
- Daugiašakio tinklo (angl. multi-branch network) - naudoja peršokimo jungtis (angl. skip connection) bei duomenys keliauja per visas paralelias šakas, po kurių gauti duomenys yra sujungti ir perduoti toliau esančiam sluoksniui [AT17].
- Celėmis pagrįsta (angl. cell-based) - naudoja normalią (angl. normal) ir mažinimo (angl. reduction) celes. Pirmoji iš celių išlaiko įeinančių duomenų erdvines dimensijas, o kita - mažina. Galutinė architektūra yra sudaroma iš celių, kurios yra sudedamos nustatytu būdu.

2.4.2. Paieškos strategija

Paieškos strategija aprašo kaip reikia tirti paieškos erdvę - surasti tinkamiausius architektūros hiperparametrus naudojant specifinį duomenų rinkinį. Paieškos erdvei tyrinėti yra naudojami įvairūs metodai, kurie yra taip pat skirti hiperparametrų optimizacijai (angl. hyperparameter optimization). NAS turi didelį persidengimą su hiperparametrų optimizavimu dėl paieškos strategijos dimensijos [FH18]. Skirtingos paieškos strategijos:

- Tinklelio paieška (angl. grid search) - rankiniu būdu išsamiai išnagrinėja nustatytą hiperparametrų konfigūraciją iki priimtino modelio tikslumo.
- Atsitiktinė paieška (angl. random search) - bandomos atsitiktinės hiperparametrų kombinacijos, kad rasti geriausią modelį. Ši strategija randa geresnius modelius net jei yra ieškoma didesnė ir mažiau perspektyvi paieškos erdvė [BB12].
- Evoliuciniai metodai (angl. evolutionary methods) - vysto modelių populiaciją (tinklų rinkinį). Kiekviename evoliucijos žingsnyje bent vienas modelis iš populiacijos yra atrenkamas ir tampa pagrindiniu (tėviniu), kad jam taikant mutacijas būtų sugeneruoti palikuonys. Mutacijos NAS kontekste yra lokalsios operacijos, kaip kad pridėjimas ar atėmimas sluoksnio, pridėjimas peršokimo jungties, hiperparametrų keitimas. Apmokius palikuonis jų tikslumas yra patikrinamas su validacijos duomenų rinkiniu, tada jie yra pridami prie populiacijos. Tuomet populiacija yra išrūšiuojama pagal tikslumą ir blogiausių pusė yra išimama iš populiacijos. Šie žingsniai vykdomi iki tol kol baigiasi nustatyti resursai [vWB18].
- Bajeso optimizacija (angl. Bayesian optimization) - efektyviai randa nežinomos funkcijos globalųjį maksimumą apibrėžtoje paieškos erdvėje. Ši strategija susideda iš dviejų dalių. Pirmoji yra surogatinis modelis, kuris susideda iš ankstesnio pasiskirstymo, kuris užfiksuoja įsitikinimus apie nežinomos objektyvios funkcijos elgesį, ir stebėjimo modelio, apibūdinančio duomenų generavimo mechanizmą. O antroji yra nuostolio funkcija, kuri aprašo užklausų sekos optimalumą [SSW⁺16].
- Skatinamasis mokymasis (angl. reinforcement learning) - generavimas architektūros gali būti laikomas agento veiksmu, kai veiksmų erdvė yra identiška paieškos erdvei. Agento apdovanojimas yra pagrįstas apmokytos architektūros veikimo tikslumu su nematytais duomenimis. Agentui nėra apibrėžiama kokius veiksmus reikia daryti, bet jis pats privalo atrasti veiksmus, kurie duoda daugiausia apdovanojimų, juos bandydamas [SB98].

2.4.3. Vykdyto vertinimo strategija

NAS tikslas yra surasti architektūrą, kuri gali įgyti aukštą nuspėjimo nustatymą (tikslumą) su nematytais duomenimis. Vykdyto vertinimas reikalingas įvertinti šį nustatymo procesą. Paprasčiausias būdas yra apmokyti ir validuoti architektūrą, bet tai daryti yra brangu ir limituoja skaičių architektūrų, kurias būtų galima ištirti. Tokiam architektūrų įvertinimui atlikti yra naudojami metodai, kurie sumažintų vykdyto vertinimo kainą:

- Nepilno veikimo tikslumo vertinimas (angl. lower fidelity estimates) - veikimas gali būti vertinamas remiantis tikslumu po pilno mokymo naudojant tikrojo veikimo mažesnią dalį - mažesnę mokymo laiko intervalą, dalį mokymo duomenų rinkinio, mažesnę paveikslukų rezoliuciją ar mažesnę filtrų kiekį per sluoksnį ir mažiau celių.
- Mokymosi kreivės ekstrapoliacija (angl. learning curve extrapolation) - mokymo laikas gali būti sumažinamas, kadangi veikimas gali būti ekstrapoliuotas po kelių mokymo epochų.
- Svorio paveldėjimas arba tinklo morfizmai (angl. weight inheritance or network morphisms) - naujos architektūros svorius nustatyti pagal jau apmokytos architektūros svorius, dėl to nereikia mokinti architektūros nuo pradžių, nes svoriai yra paveldimi. Tinklo morfizmas leidžia modifikuoti architektūrą paliekant funkciją, kuri yra reprezentuojama to tinklo, nepakeistą.
- Vieno bandymo modeliai arba svorio dalinimasis (angl. one-shot models or weight sharing) - tik vienas modelis turi būti apmokytas, nes jo svoriai yra padalijami per visas skirtingas architektūras, kurios yra pografiai pradinio modelio.

2.5. Architektūros

Konvoliuciniai neuroniniai tinklai turi keletą skirtingų architektūrų, kurios naudojamos pagal sprendžiamą problemą. 2-oje lentelėje pateikta informacija apie įvairias architektūras.

2 lentelė. Konvoliucinių neuroninių tinklų architektūros

Pavadinimas	Metai	Parametrų kiekis	Veikimas	ILSVRC vieta
LeNet	1998	60 000	Geriausiai atpažįsta ranka parašytus skaičius. Susideda iš sluoksnių - kelių pasikartojančių konvoliucijos ir sujungimo bei pasibaigia dviem pilno sujungimo sluoksniais [LJB ⁺ 95].	-

2 lentelė. Konvoliucinių neuroninių tinklų architektūros

Pavadinimas	Metai	Parametrų kiekis	Veikimas	ILSVRC vieta
AlexNet	2012	60 000 000	Veikimu panašus į LeNet, tačiau turi daug daugiau parametrų ir filtrų bei sudėtus konvoliucinius sluoksnius [ATY ⁺ 18].	pirma
GoogLeNet	2014	23 800 000	Vidiniai sluoksniai sudėti paraleliai, naudojami „Inception“ moduliai. Vienas modulis savyje turi 1x1, 3x3 ir 5x5 dydžių konvoliucijos filtrų bei vidurkio sudėjimo sluoksnius [SLJ ⁺ 14].	pirma
VGGNet	2014	138 000 000	Panašus veikimas į AlexNet, tačiau daug gilesnis. Naudojamų filtrų dydis yra 3x3 ir jie yra sudėti vienas po kito [SZ15].	antra
ResNet	2015	25 000 000	Turi labai daug sluoksnių, sudėtų vienas po kito, kurie turi liekamąjį (angl. residual) bloką, kuris įvesties informaciją perduoda tolimesniam sluoksniui ją pridėdamas ir taip sumažina konvoliucijos ir aktyvavimo funkcijų kiekį [TAL16].	pirma
CUIImage	2016	-	Dvipusis dvikryptis tinklas, kuris perduoda žinutes tarp skirtingų paramos regionų [PWR ⁺ 18].	pirma
SENet	2017	145 800 000	Panašus veikimas į ResNet, pridėtas SE blokas, kuris sujungia požymių planus ir valdo išėjimus iš kanalo [HSS17].	pirma
NASNet	2017	88 900 000	Google naudodami AutoML ir NAS algoritmą rado geriausią architektūrą ImageNet duomenų bazei. NASNet yra sudaryta iš dviejų tipų celių - normalių ir mažinimo [ZVS ⁺ 17].	-

2.6. Modelio derinimas

Apmokius neuroninį tinklą ir nustačius vidinių parametrų reikšmes gaunamas neuroninio tinklo architektūros modelis. Tokį jau egzistuojantį modelį galima derinti (angl. fine-tune) ir pritaikyti specifiniai užduočiai spręsti. Modelį derinti galima nustačius kelis paskutinius sluoksnius kaip mokomus (angl. trainable) ir su mažiau duomenų galima modelį suderinti.

Toks suderinimas yra galimas, nes pirmuosiuose sluoksniuose neuroniniai tinklai išmoksta požymių panašių į Gaboro filtrą (tiesinis filtras naudojamas tekstūroms analizuoti) ir spalvų dėmes. Šie pirmojo sluoksnio požymiai nepriklauso nuo duomenų rinkinio, bet yra bendros ir tinkamos daugeliui duomenų rinkinių ir užduočių [YCB⁺14].

2.7. Klaidų matrica

Klaidų matrica (angl. confusion matrix) yra lentelė, kuri yra naudojama parodyti klasifikacijos modelio veikimą su validacijos duomenimis, kai yra žinomos teisingos reikšmės. Matrica leidžia vizualizuoti modelio veikimą bei lengvai parodo maišymąsi tarp specifinių klasių.

Klaidų matricoje yra naudojamos šios sąvokos:

- TT (tikri teigiami) - spėjimas yra teigiamas ir jis yra teisingas.
- TN (tikri neigiami) - spėjimas yra neigiamas ir jis yra teisingas.
- NT (netikri teigiami) - spėjimas yra teigiamas, tačiau jis yra neteisingas.
- NN (netikri neigiami) - spėjimas yra neigiamas, tačiau jis yra neteisingas.

Šios sąvokos savo sutrumpinimais yra pavaizduotos 2 paveiksliuke.

Klaidų matrica

Tikras	Klasė 1	TT	NN
	Klasė 2	NT	TN
		Klasė 1	Klasė 2
		Spėtas	

2 pav. Klaidų matricos pavyzdys

Jeigu modelis įvardina dalį klasės 1 paveikslukų kaip klasę 1 tai tų paveikslukų kiekis yra įrašomas į TT matricos laukelį. Tačiau jei modelis klasės 1 paveikslukus įvardina kaip klasę 2, tai tas paveikslukų skaičius yra įrašomas į NT laukelį. Tas pats vyksta su klasės 2 paveikslukais, jeigu jie yra įvardinami kaip klasės 2 paveikslukai, tas kiekis įrašomas į TN laukelį, tačiau jei kažkiek paveikslukų įvardinama kaip klasės 1, tas skaičius įrašomas į NN laukelį.

Pagal klaidų matricos duomenis galima apskaičiuoti kelias modelio metrikas - tikslumas, atšaukimas ir precizija.

2.7.1. Tikslumas

Tikslumas (angl. accuracy) yra matavimas, kuris parodo santykį tarp teisingų spėjimų (angl. prediction) ir iš viso darytų spėjimų.

$$tikslumas = \frac{TT + TN}{TT + TN + NT + NN}. \quad (3)$$

Formulės (3) parametras TT yra skaičius tikrų teigiamų spėjimų, TN yra skaičius tikrų neigiamų spėjimų ir NT yra skaičius netikrų teigiamų spėjimų bei NN yra skaičius netikrų neigiamų spėjimų. Turinti pagal klases nesubalansuotą duomenų rinkinį (pvz. viena klasė turi daug daugiau duomenų negu likusios), tikslumo metrika nepilnai atskleidžia modelio gerumą. Pavyzdžiui, kačių nuotraukų yra 9, o šunų yra 91, modelis teisingai atpažįsta 1 katę ir 90 šunų, tikslumas bus 0.91, nors tik viena katė buvo atpažinta.

2.7.2. Atšaukimas

Atšaukimas (angl. recall) yra metrika, kuri parodo santykį tarp visų teisingų spėjimų ir visų esamų teigiamų spėjimų.

$$atšaukimas = \frac{TT}{TT + NN}. \quad (4)$$

Formulės (4) parametras TT yra skaičius tikrų teigiamų spėjimų, o NN yra skaičius netikrų neigiamų spėjimų. Sudėjus TT ir NN yra gaunama visos teigiamos reikšmės. Aukštas atšaukimas parodo, kad klasė buvo teisingai atpažinta (mažas NN).

2.7.3. Precizija

Precizija (angl. precision) parodo kiek iš visų teigiamų spėjimų, jų buvo iš tiesų teisingi.

$$precizija = \frac{TT}{TT + NT}. \quad (5)$$

Formulės (5) parametras TT yra skaičius tikrų teigiamų spėjimų, o NT yra skaičius netikrų teigiamų spėjimų. Sudėjus TT ir NT yra gaunama visi daryti teigiami spėjimai. Aukšta precizija reiškia, kad reikšmė įvardinta kaip teigiama iš ties yra teigiama (mažas NT).

3. Technologijos

Naudojamų technologijų išsirinkimas yra pradinis žingsnis siekiant įvykdyti bakalauro darbe išsikeltas užduotis. Šiame skyriuje pateiktos populiariausios šių laikų technologijos bei glaustai apibrėžti jų pagrindiniai funkcionalumai.

3.1. ImageNet

Projektas ImageNet buvo sugalvotas profesorės Li Fei-Fei 2009 metais. Projekto tikslas buvo sukurti didelę sukatégorizuotų paveiksliukų ir jų etikečių duomenų bazę, kuri būtų skirta vizualinio objektų atpažinimo programinės įrangos tyrimams. Ši duomenų bazė yra suorganizuota pagal WorldNet hierarchiją - anglų kalbos žodžiai yra grupuojami į sinonimų rinkinius, kurie turi apibūdinimus ir naudojimo pavyzdžius bei saugo ryšių kiekį tarp sinonimų arba jų narių. ImageNet turi daugiau nei 100 000 sinonimų rinkinių, kur didžioji dalis yra daiktavardžiai (80 000+).

ImageNet projektas kiekvienais metais daro konkursą vadinamą „ImageNet Large Scale Visual Recognition Challenge“ (trumpinys ILSVRC). Konkurso užduotis yra išmokinti modelį, kuris galėtų įvesties paveiksliuką teisingai klasifikuoti į 1000 skirtingų objektų klasių, kurios atitinka realius daiktus, gyvūnus ir t.t. Modeliai yra apmokomi su apie 1.2 milijonų paveiksliukų ir dar 50 000 paveiksliukų yra naudojami validacijai mokymo metu bei 100 000 paveiksliukų yra panaudojami galutiniam modelio testavimui. Šis konkursas yra paveiksliukų klasifikacijos algoritmų etalonas.

3.2. Keras

Keras yra aukšto lygio programų sąsaja skirta neuroniniams tinklams. Sąsaja parašyta su Python programavimo kalba ir vidinėje pusėje galinti veikti su „TensorFlow“ ir kitomis bibliotekomis. Keras buvo sukurtas tikintis suteikti greitą eksperimentavimą, kad sugalvojus idėją pasiekti rezultato būtų galima su kiek įmanoma mažiau uždelsimo.

Ši sąsaja savyje turi visus pagrindinius neuroninio tinklo kūrimo blokus, pavyzdžiui, sluoksniai, aktyvavimo ir optimizavimo funkcijos. Taip pat Keras suteikia modelius, kurie yra apmokyti naudojant ImageNet duomenų bazę. Šiuos modelius galima derinti, pridėti papildomų sluoksnių, pasirinkti esamus sluoksnius bei juos iš naujo apmokyti.

3.3. TensorFlow

TensorFlow yra atviros programinės įrangos biblioteka skirta aukšto našumo skaitiniams skaičiavimams. Jo lanksti architektūra leidžia lengvai diegti skaičiavimus įvairiose platformose - procesoriuose, grafikos procesoriuose. Sukurtas „Google“ dirbtinio intelekto skyriaus, tad yra labai palaikomas automatinis ir gilusis mokymasis, tačiau dėl bibliotekos ir skaičiavimų lankstumo yra naudojamas įvairiose mokslinėse srityse.

4. Modelių derinimas su mažu duomenų rinkiniu

Šio eksperimento tikslas yra išanalizuoti skirtingų gylių neuroninius tinklus pagal metrikas gautas po mokymo ir validavimo naudojant mažus duomenų rinkinius. Poskyriuje „Architektūros“ yra trumpai apibūdinti pagrindiniai konvoliucinių neuroninių tinklų tipai. Iš jų buvo išsirinktas NASNet, kadangi jis yra inovatoriškiausias ir turintis geriausią tikslumą. Negilusis modelis buvo NASNetMobile, o gilusis - NASNetLarge.

Nuspręsta daryti paprastą binarinę paveikslėlių klasifikaciją. Buvo surastos ir naudotos dvi skirtingos duomenų imtys - kačių ir šunų bei virtuvės ir svetainės. Jos abi turėjo 1400 paveikslėlių - 1 300 mokymosi tikslui ir 100 validacijos.

4.1. Tinklelio paieška

Taikant paieškos strategiją - tinklelio paiešką - buvo ieškoma geriausių hiperparametrų NASNetMobile ir NASNetLarge modeliams su dviem skirtingais duomenų rinkiniais.

Pagal naudojamo kompiuterio pajėgumą buvo nuspręsta tyrinėti:

- Išmetimo sluoksnio reikšmę - 0.25, 0.5 ir 0.75.
- Optimizavimo funkciją - RMSprop, Adam, Adagrad.
- Mokymosi greitį - 0.0005, 0.0001 ir 0.001.
- Mokomų sluoksnių skaičių - 5, 10, 20.

Iš visų šių hiperparametrų susidarė 81 kombinacijos bei jos buvo analizuojamos 4 kartus - su NASNetMobile ir dviem skirtingais duomenų rinkiniais, su NASNetLarge ir tais pačiais duomenų rinkiniais. Pagrindinis rezultatų rikiavimo kriterijus buvo tikslumas, antrinis - atšaukimas, o paskutinis buvo precizija. Visi rezultatai pateikti Prieduose esančioje 3 lentelėje. Pagal gautus rezultatus buvo nuspręsta išmetimo sluoksnio reikšmę nustatyti 0.25, optimizavimo funkciją kaip Adagrad su 0.0001 mokymosi greičiu.

4.2. Programos veikimas

Ankstesniame skyriuje „Technologijos“ yra išvardintos visos technologijos, kurios buvo naudotos šiam eksperimentui.

Eksperimentui įvykdyti reikėjo paruošti kompiuterį darbui - įrašyti „Python“ programavimo įrankius, paruošti „Anaconda“ komandinę eilutę, „NVIDIA CUDA“ įrankius, Keras ir TensorFlow. Naudojamas kompiuteris privalo turėti galingą procesorių ar grafinį procesoriaus bloką - kompiu-

teris, kuris buvo naudotas eksperimentui, turėjo Nvidia 1080 Ti.

Keras pateikia modelius, apmokytus su ImageNet, ir jų svorius, todėl reikėjo importuoti tinkamą modelį - šiuo atveju NASNet. Importavimo metu padaryti nustatymai - pilnai sujungtas sluoksnis nepridedamas, kadangi tada galima parinkti kokių dimensių paveikslukai naudojami ir kiek spalvų sluoksnių jie turi (standartiniai paveikslukai turi 3). Tuomet reikėjo nustatyti kiek importuoto modelio sluoksnių bus norima mokyti - 5, 10 ir 20. Po šių egzistuojančio modelio paruošimų reikėjo sukurti naują Kero modelį, prie kurio reikėjo pridėti paruoštą egzistuojantį modelį bei pridėti kelis kitus sluoksnius tam tikru išsidėstymu - plokštinimo (angl. flatten), tankumo (angl. dense), išmetimo (angl. dropout) ir vėl tankumo. Pirmasis tankumo sluoksnis turi aktyvacijos funkciją ReLU, o paskutinis - sigmoidinę. Po visų sluoksnių pridėjimo negilus modelis iš viso turėjo 4 405 141 parametrų, o gilusis modelis turėjo 85 916 818.

Po modelio paruošimo, reikėjo nustatyti kokio dydžio paveikslėlių partijomis (angl. batch) bus mokomas ir validuojamas modelis. Geriausias partijos dydis naudotam kompiuteriui buvo mokymosi partijai 130 paveikslėlių, o validacijos - 10. Pateikiamas paveikslėlių aplankalo kelias, klasių tipas nustatomas į binarinį, nes duomenų imtis susideda iš dviejų klasių - kačių ir šunų arba virtuvės ir svetainės.

Po modelio ir paveikslėlių rinkinio paruošimo buvo pradėta mokinti ir validuoti modelį. Taigi, modelio paruošimo metode nuostolio funkcija buvo nustatyta binarine kryžiaus entropija, o optimizavimo funkcija - Adagrad. Po modelio paruošimo buvo paleistas mokymo metodas, kuriam buvo pateikta - paruošti paveikslukai, žingsnis per epochą, epochų kiekis, paruošti validacijos paveikslukai ir jų žingsnis. Epochų kiekis šiame eksperimente buvo nustatytas 5-iems.

4.3. Modelių derinimas

Buvo pradėta derinti ir validuoti modelius su skirtingais duomenų rinkiniais ir keičiant mokomų sluoksnių skaičių.

4.3.1. Negilaus modelio derinimas


Eksperimentas buvo pradėtas nuo negilaus modelio (NASNetMobile) derinimo.

NASNetMobile modelis buvo derinamas su gyvūnų (kačių ir šunų) duomenų rinkiniu ir mokomų sluoksnių skaičius buvo nustatytas 5-iems. Po derinimo buvo gauti tikslumo ir nuostolio grafikai - 15 ir 16 pav. (Priedas nr. 2). Iš jų matyti kad mokymo tikslumas tiesiškai augo, o nuostolis tiesiškai mažėjo, tačiau validacijos tikslumas nuo 0.5 pakilo tik 0.05 ir nuostolis išliko


aukštas.

Po to modelis buvo derinamas su kambarių (virtuvės ir svetainės) duomenų rinkiniu bei tokiu pačiu mokomų sluoksnių skaičiumi. Gauti rezultatai pateikti 17 ir 18 pav. (Priedas nr. 2). Mokymo ir validacijos tikslumas nepasiekė tokio tikslumo kaip kad modelį derinant su gyvūnų rinkiniu, nors ir mokymo tikslumas nuolatos didėjo, validacijos tikslumas svyravo ir paskutinėje epochoje pasiekė mažiausias reikšmes. Tačiau nuostolio grafikas parodo tokias pačias tendencijas kaip kad derinant su gyvūnų rinkiniu.

Taigi, iš gautų klaidų matricų (3 ir 4 pav.) galima matyti, jog derinant modelį su gyvūnų rinkiniu klasės buvo geriau nustatytos. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.57, atšaukimas - 0.94, precizija - 0.54, kai su kambarių rinkiniu buvo gautas tikslumas - 0.53, atšaukimas - 0.74, precizija - 0.52.



3 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu




4 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu


Iš naujo buvo derinamas negilus modelis su gyvūnų rinkiniu ir su 10 mokomų sluoksnių. Po derinimo gauti rezultatai pateikti 19 ir 20 pav. (Priedas nr. 2). Mokymo tikslumas nuolatos didėjo, o validacijos svyravo, tačiau paskutinėse epochose išsitiesino. O mokymo ir validacijos nuostolis nuolatos mažėjo.

Modelis buvo derinamas su tokiu pačiu mokomų sluoksnių skaičiumi, bet su kambarių duomenų rinkiniu. Gauti rezultatai pateikti 21 ir 22 pav. (Priedas nr. 2). Mokymo tikslumas visą laiką buvo mažesnis negu validacijos, tačiau paskutinėje epochoje tikslumai pasiekė tokią pačią reikšmę. O mokymo nuostolis nuolatos mažėjo ir po paskutinės epochos buvo mažesnis už validacijos.

Po šių derinimų buvo gautos klaidų matricos - 5 ir 6 pav. Su tokiu mokomų sluoksnių skaičiumi modelis derinamas su kambarių rinkiniu teisingai atpažino daugiau klasių negu kad modelis su gyvūnų rinkiniu. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.52, atšaukimas - 0.28, precizija - 0.54, kai su kambarių rinkiniu buvo gautas tikslumas - 0.55, atšaukimas - 0.80, precizija - 0.53.



5 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu




6 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu


Negilaus modelio derinimas buvo daromas su 20 mokomų sluoksnių ir gyvūnų duomenų rinkiniu. Po derinimo buvo gauti tikslumo ir nuostolio grafikai - 23 ir 24 pav. (Priedas nr. 2). Juose pateikta kad mokymo ir validacijos tikslumas kilo, nors validacijos tikslumas 2-oje epochoje buvo sumažėjęs. O nuostolio grafikai pateikta kad mokymo ir validacijos reikšmės nuolatos mažėjo, tačiau mokymo nuostolis mažėjo daug greičiau.

Paskutinis NASNetMobile modelio derinimas buvo daromas su kambarių duomenų rinkiniu ir tokiu pačiu mokomų sluoksnių skaičiumi kaip kad su gyvūnų rinkiniu. Gauti rezultatai pateikti 25 ir 26 pav. (Priedas nr. 2). Juose yra pateikta jog mokymo ir validacijos tikslumas nuolatos didėjo, o nuostolis mažėjo. Nors validacijos tikslumas ir nuostolis daug plokščiau keitėsi negu kad mokymosi tikslumas ir nuostolis.

Po paskutinių negilaus modelio derinimų buvo gautos klaidų matricos, kurios pateiktos 7 ir 8 pav. Jose parodyta jog modelis derintas su gyvūnų duomenų rinkiniu pranoko modelį derintą su kambarių duomenų rinkiniu. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.69, atšaukimas - 1.00, precizija - 0.62, kai su kambarių rinkiniu buvo gautas tikslumas - 0.61, atšaukimas - 0.88, precizija - 0.57.



7 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu



8 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu

Taigi, derinant negilų modelį su gyvūnų arba kambarių duomenų rinkiniais aukščiausias tikslumas, atšaukimas ir precizija buvo pasiekti mokomų sluoksnių skaičių nustačius 20. Taip pat modeliai, kurie buvo suderinti su gyvūnų duomenų rinkiniu, dažniau pasiekė aukštesnius rezultatus negu modeliai, kurie buvo suderinti su kambarių rinkiniu.

4.3.2. Gilaus modelio derinimas


Eksperimentas buvo pratęstas naudojant gilų modelį (NASNetLarge).

Gilų modelį derinti buvo pradėta su gyvūnų duomenų rinkiniu ir 5-iais mokomais sluoksniais. Gauti rezultatai pateikti 27 ir 28 pav. (Priedas nr. 2). Modelio mokymo tikslumas augo logaritmiškai, o validacijos tikslumas nuolatos plokščiai mažėjo. Nors mokymo ir validacijos nuostoliai panašiai nuolatos mažėjo.


Po to gilus modelis buvo apmokytas su kambarių duomenų rinkiniu ir 5-iais mokomais sluoksniais. Po derinimo buvo gauti tikslumo ir nuostolio grafikai - 29 ir 30 pav. (Priedas nr. 2). Juose pateikta kad validacijos tikslumas šiek tiek svyravo, bet nuolatos augo ir buvo didesnis už mokymo tikslumą. O mokymo ir validacijos nuostoliai nuolatos panašiai mažėjo.

Po derinimų buvo gautos klaidų matricos, kurios pateiktos 9 ir 10 pav. Jose parodyta, jog modelis suderintas su gyvūnų duomenų rinkiniu atpažino šiek tiek daugiau klasių negu kad modelis apmokytas su kambarių duomenų rinkiniu. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.92, atšaukimas - 0.98, precizija - 0.88, kai su kambarių rinkiniu buvo gautas tikslumas - 0.87,

atšaukimas - 0.86, precizija - 0.88.



9 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu



10 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu


NASNetLarge buvo derinamas su gyvūnų duomenų rinkiniu ir mokomų sluoksnių skaičius buvo nustatytas 10. Gauti rezultatai pateikti 31 ir 32 pav. (Priedas nr. 2). Juose pateikta jog mokymo ir validacijos tikslumas auga, tačiau paskutinėse keliuose epochose pradeda mažėti. O mokymo ir validacijos nuostoliai nuolatos mažėja.

Modelis iš naujo derinamas su kambarių duomenų rinkiniu ir tokiu pačiu mokomų sluoksnių skaičiumi kaip kad su gyvūnų rinkiniu. Po derinimo buvo gauti grafikai - 33 ir 34 pav. (Priedas nr. 2). Mokymo ir validacijos tikslumas nuolatos didėjo, tačiau validacijos tikslumas buvo nuolatos didesnis už mokymo. Nors mokymo ir validacijos nuostoliai nuolatos mažėja.


Po padarytų modelių derinimų buvo gautos klaidų matricos - 11 ir 12 pav., kuriose pateikta jog modelis, kuris buvo derinamas su gyvūnų rinkiniu, teisingai atpažino daugiau klasių. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.93, atšaukimas - 1.00, precizija - 0.88, kai su kambarių rinkiniu buvo gautas tikslumas - 0.91, atšaukimas - 0.92, precizija - 0.90.

Gilus modelis buvo derinamas su gyvūnų duomenų rinkiniu ir mokomų sluoksnių skaičius buvo nustatytas 20. Po derinimo buvo gauti grafikai - 35 ir 36 pav. (Priedas nr. 2). Juose pateikta jog modelio mokymo tikslumas nuolatos augo, o validacijos tikslumas šiek tiek svyravo. O mokymo ir validacijos nuostoliai nuolatos mažėja.

Paskutiniame NASNetLarge modelio derinime buvo naudotas kambarių duomenų rinkinys ir 20-imt mokomų sluoksnių. Gauti rezultatai pateikti 37 ir 38 pav. (Priedas nr. 2). Juose parodyta




11 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu




12 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu

kad mokymo ir validacijos tikslumas nuolatos augo, tačiau tikslumas prieš paskutinėje epochoje pradėjo mažėti. Nors mokymo ir validacijos nuostoliai nuolatos mažėja.

Po paskutinių modelio derinimų gautos klaidų matricos, kurios pateiktos 13 ir 14 pav., kuriose pateikta jog modelis suderintas su gyvūnų duomenų rinkiniu teisingai atpažino daugiau klasių negu kad kitas modelis. Su gyvūnų rinkiniu buvo pasiektas tikslumas - 0.96, atšaukimas - 1.00, precizija - 0.93, kai su kambarių rinkiniu buvo gautas tikslumas - 0.89, atšaukimas - 0.92, precizija - 0.87.



13 pav. Klaidų matrica gauta su gyvūnų duomenų rinkiniu



14 pav. Klaidų matrica gauta su kambarių duomenų rinkiniu

Taigi, geriausius rezultatus modelis suderintas su gyvūnų duomenų rinkiniu pasiekia naudojant

20 mokomų sluoksnių, o modelis suderintas su kambarių duomenų rinkiniu pasiekia aukščiausius rezultatus mokomų sluoksnių skaičių nustačius 10.

Rezultatai

Šio darbo metu buvo tirta dirbtinių neuroninių tinklų ir konvoliucinių neuroninių tinklų veikimas ir jų sudedamosios dalys bei surinkta informacija iš literatūros šaltinių. Atliktas eksperimentas, kurio tikslas buvo pamatyti kokį poveikį turi konvoliucinio neuroninio tinklo gylis ir jo suderinimui naudojamas mažas duomenų rinkinys neuroninio tinklo metrikoms - tikslumui, atšaukimui, precizijai.

Darbo rezultatai:

1. Buvo atlikta bendra dirbtinių neuroninių tinklų ir konvoliucinių neuroninių tinklų bei NAS algoritmo analizė.
2. Buvo rasti geriausi hiperparametrai (optimizavimo funkcija, mokymosi greitis, išmetimo sluoksnio reikšmė) NASNetLarge ir NASNetMobile modeliams naudojant du skirtingus duomenų rinkinius bei keičiant mokomų sluoksnių skaičių.
3. Egzistuojantys NASNetLarge ir NASNetMobile modeliai buvo modifikuoti binariniai klasifikacijai ir suderinti naudojant du skirtingus duomenų rinkinius - kačių ir šunų bei virtuvės ir svetainės.
4. Gauti skirtingų gylių suderintų modelių mokymo ir validacijos tikslumo grafikai bei klaidų matricos.

Išvados

Atlikus literatūros šaltinių analizę ir eksperimentą buvo padarytos išvados:

1. Suderinus skirtingų gylių modelius su dviem skirtingais mažais duomenų rinkiniais ir keičiant mokomų sluoksnių skaičių, buvo nustatyta, kad gilesnis tinklas pasiekė daug aukštesnius rezultatus (tikslumą, atšaukimą, preciziją) negu negilus modelis. Gilaus modelio validacijos tikslumo vidurkis buvo 0.91, atšaukimo vidurkis buvo 0.95 ir precizijos buvo 0.89, kai su tokiais pačiais hiperparametrais ir duomenų rinkiniais negilaus modelio validacijos tikslumo vidurkis buvo 0.58, atšaukimo vidurkis buvo 0.77 bei precizijos vidurkis buvo 0.55. Taigi, šio eksperimento metu gilesnis tinklas pasiekė 58% didesnę tikslumą, 22% didesnę atšaukimą ir 60% didesnę preciziją palyginus su negilaus modelio rezultatais.
2. Modelis, kuris buvo pirmiausia apmokytas su duomenų rinkiniu, kuriame egzistuoja klasės sutampančios su derinimui naudojamu duomenų rinkinio klasėmis, po suderinimo gaus šiek tiek geresnius rezultatus negu kad toks pat modelis, kuris buvo suderintas su duomenų rinkiniu, kurio klasės nesutampa. Tai buvo nustatyta, kadangi naudojami modeliai buvo apmokyti su ImageNet duomenų baze, kurioje egzistuoja kačių ir šunų klasės, o derinant šiuos modelius su kačių ir šunų duomenų rinkiniais buvo gautas validacijos tikslumo vidurkis 0.77, atšaukimo vidurkis buvo 0.87 bei precizijos vidurkis buvo 0.73, o modelių suderintų su virtuvės ir svetainės duomenų rinkiniu validacijos tikslumo vidurkis buvo 0.73, atšaukimo vidurkis buvo 0.85, o precizijos vidurkis buvo 0.71. Taigi, suderintas modelis su duomenų rinkiniu, kurio klasės yra žinomos modeliui, pasiekia 5% didesnę tikslumą, 1% didesnę atšaukimą ir 2% didesnę preciziją negu suderintas modelis su duomenų rinkiniu, kurio klasės yra naujos modeliui.
3. Mokomų sluoksnių skaičius buvo keičiamas derinant skirtingų gylių modelius su dviem skirtingais mažais duomenų rinkiniais. Buvo pasirinkti sluoksnių skaičiai - 5, 10 ir 20. Palyginus visus bandymus geriausi rezultatai buvo pasiekti mokomų sluoksnių skaičių nustačius 20, tačiau derinant gilesnį modelį su virtuvės ir svetainės duomenų rinkiniu geriausias rezultatas buvo pasiektas su 10 mokomų sluoksnių. Su 5-iais mokomais sluoksniais modelis turėjo 0.72 tikslumo vidurkį, 0.88 atšaukimo vidurkį ir 0.71 precizijos vidurkį, su 10-imt mokomų sluoksnių modelio tikslumo vidurkis buvo 0.73, atšaukimo vidurkis buvo 0.75 bei precizijos vidurkis buvo 0.71. Tačiau su 20-imt mokomų sluoksnių modelis turėjo 0.79 tikslumo vidurkį, 0.95 atšaukimo vidurkį ir 0.75 precizijos vidurkį. Taigi, nustačius mokomų sluoksnių skaičių kaip 20 buvo pasiekti geresni rezultatai.

Literatūra

- [AT17] Karim Ahmed ir Lorenzo Torresani. Connectivity learning in multi-branch networks. *CoRR*, abs/1709.09582, 2017. arXiv: 1709.09582. URL: <http://arxiv.org/abs/1709.09582>.
- [ATY⁺18] Md. Zahangir Alom, Tarek M. Taha, Christopher Yakopcic, Stefan Westberg, Mahmudul Hasan, Brian C. Van Esesn, Abdul A. S. Awwal ir Vijayan K. Asari. The history began from alexnet: A comprehensive survey on deep learning approaches. *CoRR*, abs/1803.01164, 2018. arXiv: 1803.01164. URL: <http://arxiv.org/abs/1803.01164>.
- [BB12] James Bergstra ir Yoshua Bengio. Random search for hyper-parameter optimization. *J. Mach. Learn. Res.*, 13(1):281–305, 2012-02. ISSN: 1532-4435. URL: <http://dl.acm.org/citation.cfm?id=2503308.2188395>.
- [BX16] Su Chang Bian Ziyang Xu Tingfa ir Luo Xuan. Human abnormal behavior detection based on rgbd video’s skeleton information entropy. *Proceedings of the 2015 International Conference on Communications, Signal Processing, and Systems*, p. 715–723. Springer Berlin Heidelberg, 2016. ISBN: 978-3-662-49831-6.
- [CLS⁺15] Junghwan Cho, Kyewook Lee, Ellie Shin, Garry Choy ir Synho Do. Medical image deep learning with hospital PACS dataset. *CoRR*, abs/1511.06348, 2015. arXiv: 1511.06348. URL: <http://arxiv.org/abs/1511.06348>.
- [Dav15] Cameron Davidson-Pilon. *Bayesian Methods for Hackers*. Addison-Wesley Professional, 2015.
- [EMH18] Thomas Elsken, Jan Hendrik Metzen ir Frank Hutter. Neural architecture search: a survey. *arXiv preprint arXiv:1808.05377*, 2018.
- [Epp17] Sagi Eppel. Setting an attention region for convolutional neural networks using region selective features, for recognition of materials within glass vessels. *CoRR*, abs/1708.08711, 2017. arXiv: 1708.08711. URL: <http://arxiv.org/abs/1708.08711>.
- [FH18] Matthias Feurer ir Frank Hutter. Hyperparameter optimization. Frank Hutter, Lars Kotthoff ir Joaquin Vanschoren, redaktoriai, *AutoML: Methods, Sytems, Challenges*, skyr. 1, p. 3–37. Springer, 2018. To appear.

- [Fuk80] Kunihiro Fukushima. Neocognitron: a self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. 36:193–202, 1980-02.
- [Gau15] Ranjana Raut Gauri Borkhade. Application of neural network for diagnosing eye disease. *International Journal of Electronics, Communication and Soft Computing Science and Engineering (IJECSCE)*, 4:174–176, 2015. Published By International Journal of Electronics, Communication and Soft Computing Science and Engineering.
- [GBC16] Ian Goodfellow, Yoshua Bengio ir Aaron Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [GVR⁺10] N. Ganesan, K. Venkatesh, M. A. Rama ir A. Malathi Palani. Article:application of neural networks in diagnosing cancer disease using demographic data. *International Journal of Computer Applications*, 1(26):76–85, 2010-02. Published By Foundation of Computer Science.
- [HKV19] Frank Hutter, Lars Kotthoff ir J. Vanschoren. *Automatic machine learning: methods, systems, challenges*. English. Challenges in Machine Learning. Springer, Germany, 2019. ISBN: 978-3-030-05317-8. DOI: 10.1007/978-3-030-05318-5.
- [HSS17] Jie Hu, Li Shen ir Gang Sun. Squeeze-and-excitation networks. *CoRR*, abs/1709.01507, 2017. arXiv: 1709.01507. URL: <http://arxiv.org/abs/1709.01507>.
- [YCB⁺14] Jason Yosinski, Jeff Clune, Yoshua Bengio ir Hod Lipson. How transferable are features in deep neural networks? *CoRR*, abs/1411.1792, 2014. arXiv: 1411.1792. URL: <http://arxiv.org/abs/1411.1792>.
- [YK18] Adam JATOWT Yihong ZHANG ir Yukiko KAWAI. Picture or words: predicting twitter image post popularity with deep learning, 2018. URL: <http://db-event.jp/jpn.org/deim2018/data/papers/365.pdf>.
- [Leo98] C.T. Leondes. *Image Processing and Pattern Recognition*. Neural Network Systems Techniques and Applications. Elsevier Science, 1998, p. 323–324. ISBN: 9780080551449. URL: <https://books.google.lt/books?id=oDewAeVxr-4C>.
- [LGT18] C. Y. Lee, P. Gallagher ir Z. Tu. Generalizing pooling functions in cnns: mixed, gated, and tree. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(4):863–875, 2018-04. ISSN: 0162-8828. DOI: 10.1109/TPAMI.2017.2703082.

- [LHB⁺99] Yann LeCun, Patrick Haffner, Léon Bottou ir Yoshua Bengio. Object recognition with gradient-based learning. *Shape, Contour and Grouping in Computer Vision*, p. 319–, London, UK, UK. Springer-Verlag, 1999. ISBN: 3-540-66722-9. URL: <http://dl.acm.org/citation.cfm?id=646469.691875>.
- [Li15] Fei-Fei Li. Convolutional neural networks. <https://cs231n.github.io/convolutional-networks/>, 2015.
- [LJB⁺95] Yann LeCun, LD Jackel, Leon Bottou, A Brunot ir k.t. Comparison of learning algorithms for handwritten digit recognition. *International conference on artificial neural networks*, tom. 60, p. 53–60. Perth, Australia, 1995.
- [LMH⁺19] Jason Zhi Liang, Elliot Meyerson, Babak Hodjat, Daniel Fink, Karl Mutch ir Risto Miikkulainen. Evolutionary neural automl for deep learning. *CoRR*, abs/1902.06827, 2019. arXiv: 1902.06827. URL: <http://arxiv.org/abs/1902.06827>.
- [Nik16] Mina Niknafs. Neural network optimization. 2016.
- [Pau01] Colm O’ Riordan Paul O’ Dea Josephine Griffith. Combining feature selection and neural networks for solving classification problems. *Intelligent Exploration of the Web*:389–401, 2001-07.
- [PG17] Josh Patterson ir Adam Gibson. *Deep Learning*. O’Reilly Media, Inc., 2017.
- [PWR⁺18] Zhanglin Peng, Lingyun Wu, Jiamin Ren, Ruimao Zhang ir Ping Luo. Cuimage: a neverending learning platform on a convolutional knowledge graph of billion web images. *2018 IEEE International Conference on Big Data (Big Data)*:1787–1796, 2018.
- [Ras15] Sebastian Raschka. *Python Machine Learning*. Packt Publishing, 2015, p. 342–343. ISBN: 1783555130, 9781783555130.
- [RMS⁺17] Esteban Real, Sherry Moore, Andrew Selle, Saurabh Saxena, Yutaka Leon Suematsu, Quoc V. Le ir Alex Kurakin. Large-scale evolution of image classifiers. *CoRR*, abs/1703.01041, 2017. arXiv: 1703.01041. URL: <http://arxiv.org/abs/1703.01041>.
- [RPA⁺18] Reza Reiazi, Reza Paydar, Ali Abbasian Ardakani ir Maryam Etedadialiabadi. Mammography lesion detection using faster r-cnn detector, 2018-01.
- [RS17] Thaqif Rajab ir Roselina Salleh. Classification of diabetes disease using backpropagation and radial basis function network. 2:3–4, 2017.

- [Rud16] Sebastian Ruder. An overview of gradient descent optimization algorithms. *CoRR*, abs/1609.04747, 2016. arXiv: 1609.04747. URL: <http://arxiv.org/abs/1609.04747>.
- [SB98] Richard S. Sutton ir Andrew G. Barto. *Introduction to Reinforcement Learning*. MIT Press, Cambridge, MA, USA, 1st leid., 1998. ISBN: 0262193981.
- [Shi12] D. Shiffman. *The Nature of Code*. D. Shiffman, 2012. Skyr. 10. ISBN: 9780985930806. URL: <https://books.google.lt/books?id=hoK6lgEACAAJ>.
- [Sin18] Arvind Kumar Sinha. Interweaving convolutions : an application to audio classification harsh. 2018.
- [SLJ⁺14] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott E. Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke ir Andrew Rabinovich. Going deeper with convolutions. *CoRR*, abs/1409.4842, 2014. arXiv: 1409.4842. URL: <http://arxiv.org/abs/1409.4842>.
- [SSS⁺17] Chen Sun, Abhinav Shrivastava, Saurabh Singh ir Abhinav Gupta. Revisiting unreasonable effectiveness of data in deep learning era. *CoRR*, abs/1707.02968, 2017. arXiv: 1707.02968. URL: <http://arxiv.org/abs/1707.02968>.
- [SSW⁺16] B. Shahriari, K. Swersky, Z. Wang, R. P. Adams ir N. de Freitas. Taking the human out of the loop: a review of bayesian optimization. *Proceedings of the IEEE*, 104(1):148–175, 2016-01. ISSN: 0018-9219. DOI: 10.1109/JPROC.2015.2494218.
- [SZ15] Karen Simonyan ir Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *CoRR*, abs/1409.1556, 2015.
- [TAL16] Sasha Targ, Diogo Almeida ir Kevin Lyman. Resnet in resnet: generalizing residual architectures. *CoRR*, abs/1603.08029, 2016. arXiv: 1603.08029. URL: <http://arxiv.org/abs/1603.08029>.
- [TL14] Ranzato Marc'Aurelio Taigman Yaniv Yang Ming ir Wolf Lior. Deepface: closing the gap to human-level performance in face verification. *Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition*, p. 1701–1708. IEEE Computer Society, 2014. ISBN: 978-1-4799-5118-5. DOI: 10.1109/CVPR.2014.220. URL: <https://doi.org/10.1109/CVPR.2014.220>.
- [VK11] A Vehbi Olgac ir Bekir Karlik. Performance analysis of various activation functions in generalized mlp architectures of neural networks. 1:111–122, 2011-02.

- [vWB18] Gerard Jacques van Wyk ir Anna Sergeevna Bosman. Evolutionary neural architecture search for image restoration. *CoRR*, abs/1812.05866, 2018. arXiv: 1812.05866. URL: <http://arxiv.org/abs/1812.05866>.
- [WZL⁺19] Y. Weng, T. Zhou, L. Liu ir C. Xia. Automatic convolutional neural architecture search for image classification under different scenes. *IEEE Access*, 7:38495–38506, 2019. ISSN: 2169-3536. DOI: 10.1109/ACCESS.2019.2906369.
- [ZGD03] Qi-Jun Zhang, K. C. Gupta ir V. K. Devabhaktuni. Artificial neural networks for rf and microwave design - from theory to practice. *IEEE Transactions on Microwave Theory and Techniques*, 51(4):1339–1350, 2003-04. ISSN: 0018-9480. DOI: 10.1109/TMTT.2003.809179.
- [ZVS⁺17] Barret Zoph, Vijay Vasudevan, Jonathon Shlens ir Quoc V. Le. Learning transferable architectures for scalable image recognition. *CoRR*, abs/1707.07012, 2017. arXiv: 1707.07012. URL: <http://arxiv.org/abs/1707.07012>.

Priedas nr. 1

Tinklelio paieška

Hiperparametrų stulpelyje yra pateiktos išmetimo sluoksnio, optimizacijos funkcijos, mokymosi greičio reikšmės. Jų tyrinėjimas buvo atliktas su NASNetLarge ir NASNetMobile modeliais naudojant gyvūnų (kačių ir šunų) ir kambarių (virtuvės ir svetainės) duomenų rinkinius bei keičiant mokomų sluoksnių skaičių (5, 10 ir 20). Kiekviename rezultatų langelyje pateiktos tikslumo, atšaukimo ir precizijos reikšmės. Paryškintos reikšmės parodo geriausius rezultatus tame stulpelyje.

3 lentelė. Rezultatai

Hiperpara- metrai	NASNetLarge						NASNetMobile					
	Gyvūnai			Kambariai			Gyvūnai			Kambariai		
	5	10	20	5	10	20	5	10	20	5	10	20
0.25, RMSprop, 0.0005	0.96; 0.94; 0.98	0.89; 0.78; 1.0	0.96; 0.92; 1.0	0.89; 0.84; 0.93	0.88; 0.8; 0.95	0.86; 0.74; 0.97	0.67; 0.34; 1.0	0.69; 0.38; 1.0	0.58; 0.16; 1.0	0.5; 0.0; 0.0	0.53; 0.06; 1.0	0.54; 0.08; 1.0
0.25, RMSprop, 0.0001	0.92; 0.84; 1.0	0.95; 0.9; 1.0	0.98; 0.96; 1.0	0.88; 0.84; 0.91	0.91; 0.88; 0.94	0.88; 0.82; 0.93	0.6; 0.2; 1.0	0.7; 0.44; 0.92	0.61; 0.22; 1.0	0.51; 0.02; 1.0	0.58; 0.24; 0.75	0.58; 0.16; 1.0
0.25, RMSprop, 0.001	0.93; 0.86; 1.0	0.92; 0.84; 1.0	0.92; 0.84; 1.0	0.85; 0.72; 0.97	0.85; 0.86; 0.84	0.91; 0.9; 0.92	0.63; 0.26; 1.0	0.62; 0.24; 1.0	0.58; 0.16; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.66; 0.32; 1.0
0.25, Adam, 0.0005	0.91; 0.82; 1.0	0.91; 0.82; 1.0	0.93; 0.86; 1.0	0.89; 0.82; 0.95	0.88; 0.8; 0.95	0.89; 0.82; 0.95	0.56; 0.12; 1.0	0.67; 0.34; 1.0	0.62; 0.24; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.52; 0.04; 1.0
0.25, Adam, 0.0001	0.95; 0.9; 1.0	0.94; 0.88; 1.0	0.93; 0.86; 1.0	0.88; 0.8; 0.95	0.9; 0.86; 0.93	0.89; 0.84; 0.93	0.62; 0.24; 1.0	0.69; 0.4; 0.95	0.61; 0.22; 1.0	0.54; 0.16; 0.67	0.48; 0.02; 0.25	0.51; 0.02; 1.0
0.25, Adam, 0.001	0.93; 0.86; 1.0	0.92; 0.84; 1.0	0.94; 0.88; 1.0	0.89; 0.82; 0.95	0.88; 0.8; 0.95	0.88; 0.8; 0.95	0.63; 0.26; 1.0	0.65; 0.3; 1.0	0.63; 0.26; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.66; 0.32; 1.0
0.25, Adagrad, 0.0005	0.94; 0.88; 1.0	0.93; 0.86; 1.0	0.95; 0.9; 1.0	0.86; 0.78; 0.93	0.89; 0.84; 0.93	0.9; 0.86; 0.93	0.6; 0.2; 1.0	0.62; 0.24; 1.0	0.63; 0.26; 1.0	0.52; 0.04; 1.0	0.63; 0.36; 0.78	0.49; 0.0; 0.0
0.25, Adagrad, 0.0001	0.98; 0.96; 1.0	0.96; 0.92; 1.0	0.96; 0.92; 1.0	0.85; 0.78; 0.91	0.87; 0.94; 0.82	0.9; 0.88; 0.92	0.56; 0.18; 0.75	0.55; 0.1; 1.0	0.61; 0.22; 1.0	0.54; 0.4; 0.56	0.63; 0.56; 0.65	0.59; 0.26; 0.76

3 lentelė. Rezultatai

Hiperpara- metrai	NASNetLarge						NASNetMobile					
	Gyvūnai			Kambariai			Gyvūnai			Kambariai		
	5	10	20	5	10	20	5	10	20	5	10	20
0.25, Adagrad, 0.001	0.93; 0.86; 1.0	0.92; 0.84; 1.0	0.96; 0.92; 1.0	0.88; 0.82; 0.93	0.85; 0.72; 0.97	0.88; 0.78; 0.97	0.67; 0.34; 1.0	0.65; 0.3; 1.0	0.67; 0.34; 1.0	0.5; 0.0; 0.0	0.52; 0.04; 1.0	0.52; 0.04; 1.0
0.5, RM-Sprop, 0.0005	0.9; 0.8; 1.0	0.97; 0.94; 1.0	0.89; 0.78; 1.0	0.9; 0.82; 0.98	0.88; 0.86; 0.9	0.88; 0.78; 0.97	0.65; 0.3; 1.0	0.59; 0.18; 1.0	0.66; 0.32; 1.0	0.5; 0.0; 0.0	0.51; 0.02; 1.0	0.58; 0.16; 1.0
0.5, RM-Sprop, 0.0001	0.95; 0.9; 1.0	0.98 ; 0.96 ; 1.0	0.95; 0.9; 1.0	0.89; 0.84; 0.93	0.9; 0.88; 0.92	0.88; 0.82; 0.93	0.58; 0.16; 1.0	0.59; 0.18; 1.0	0.72; 0.44; 1.0	0.55; 0.1; 1.0	0.54; 0.14; 0.7	0.52; 0.04; 1.0
0.5, RM-Sprop, 0.001	0.95; 0.9; 1.0	0.89; 0.78; 1.0	0.93; 0.86; 1.0	0.88; 0.8; 0.95	0.89; 0.9; 0.88	0.85; 0.72; 0.97	0.63; 0.26; 1.0	0.55; 0.1; 1.0	0.62; 0.24; 1.0	0.5; 0.0; 0.0	0.52; 0.04; 1.0	0.57; 0.14; 1.0
0.5, Adam, 0.0005	0.91; 0.82; 1.0	0.91; 0.82; 1.0	0.95; 0.9; 1.0	0.86; 0.74; 0.97	0.88; 0.8; 0.95	0.89; 0.8; 0.98	0.63; 0.26; 1.0	0.68; 0.4; 0.91	0.67; 0.34; 1.0	0.51; 0.02; 1.0	0.51; 0.02; 1.0	0.52; 0.04; 1.0
0.5, Adam, 0.0001	0.95; 0.9; 1.0	0.93; 0.86; 1.0	0.93; 0.86; 1.0	0.89; 0.84; 0.93	0.89; 0.82; 0.95	0.88; 0.82; 0.93	0.76 ; 0.54 ; 0.96	0.6; 0.2; 1.0	0.65; 0.3; 1.0	0.63; 0.3; 0.88	0.54; 0.16; 0.67	0.52; 0.04; 1.0
0.5, Adam, 0.001	0.88; 0.76; 1.0	0.93; 0.86; 1.0	0.95; 0.9; 1.0	0.86; 0.74; 0.97	0.86; 0.74; 0.97	0.88; 0.78; 0.97	0.55; 0.1; 1.0	0.65; 0.3; 1.0	0.61; 0.22; 1.0	0.5; 0.0; 0.0	0.51; 0.02; 1.0	0.63; 0.26; 1.0
0.5, Adagrad, 0.0005	0.93; 0.86; 1.0	0.94; 0.88; 1.0	0.95; 0.9; 1.0	0.88; 0.84; 0.91	0.89; 0.82; 0.95	0.87; 0.8; 0.93	0.59; 0.18; 1.0	0.77 ; 0.66 ; 0.85	0.71; 0.42; 1.0	0.64 ; 0.32 ; 0.89	0.51; 0.04; 0.67	0.51; 0.02; 1.0
0.5, Adagrad, 0.0001	0.95; 0.9; 1.0	0.93; 0.86; 1.0	0.94; 0.88; 1.0	0.8; 0.9; 0.75	0.88; 0.84; 0.91	0.88; 0.9; 0.87	0.59; 0.34; 0.68	0.66; 0.9; 0.61	0.57; 0.14; 1.0	0.45; 0.18; 0.39	0.51; 0.02; 1.0	0.48; 0.2; 0.45
0.5, Adagrad, 0.001	0.93; 0.86; 1.0	0.93; 0.86; 1.0	0.96; 0.92; 1.0	0.88; 0.84; 0.91	0.89; 0.82; 0.95	0.9; 0.82; 0.98	0.54; 0.08; 1.0	0.67; 0.34; 1.0	0.68; 0.36; 1.0	0.5; 0.0; 0.0	0.56; 0.14; 0.88	0.5; 0.0; 0.0
0.7, RM-Sprop, 0.0005	0.95; 0.9; 1.0	0.94; 0.88; 1.0	0.96; 0.92; 1.0	0.87; 0.76; 0.97	0.9; 0.88; 0.92	0.89; 0.84; 0.93	0.66; 0.32; 1.0	0.56; 0.12; 1.0	0.63; 0.26; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.54; 0.08; 1.0


3 lentelė. Rezultatai

Hiperpara- metrai	NASNetLarge						NASNetMobile					
	Gyvūnai			Kambariai			Gyvūnai			Kambariai		
	5	10	20	5	10	20	5	10	20	5	10	20
0.7, RM-Sprop, 0.0001	0.95; 0.9; 1.0	0.94; 0.88; 1.0	0.98; 0.96; 1.0	0.9; 0.86; 0.93	0.89; 0.84; 0.93	0.89; 0.84; 0.93	0.63; 0.28; 0.93	0.68; 0.38; 0.95	0.7; 0.4; 1.0	0.5; 0.0; 0.0	0.55; 0.1; 1.0	0.51; 0.02; 1.0
0.7, RM-Sprop, 0.001	0.91; 0.82; 1.0	0.97; 0.94; 1.0	0.93; 0.86; 1.0	0.88; 0.78; 0.97	0.9; 0.86; 0.93	0.88; 0.78; 0.97	0.7; 0.4; 1.0	0.62; 0.24; 1.0	0.64; 0.28; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.51; 0.02; 1.0
0.7, Adam, 0.0005	0.92; 0.84; 1.0	0.92; 0.84; 1.0	0.94; 0.88; 1.0	0.88; 0.78; 0.97	0.88; 0.82; 0.93	0.89; 0.82; 0.95	0.63; 0.26; 1.0	0.64; 0.28; 1.0	0.63; 0.26; 1.0	0.5; 0.0; 0.0	0.5; 0.0; 0.0	0.57; 0.14; 1.0
0.7, Adam, 0.0001	0.93; 0.86; 1.0	0.94; 0.88; 1.0	0.93; 0.86; 1.0	0.9; 0.86; 0.93	0.89; 0.88; 0.9	0.89; 0.84; 0.93	0.75; 0.58; 0.88	0.71; 0.62; 0.76	0.68; 0.36; 1.0	0.59; 0.26; 0.76	0.5; 0.02; 0.5	0.52; 0.04; 1.0
0.7, Adam, 0.001	0.94; 0.88; 1.0	0.94; 0.88; 1.0	0.92; 0.84; 1.0	0.88; 0.78; 0.97	0.87; 0.78; 0.95	0.87; 0.78; 0.95	0.66; 0.32; 1.0	0.64; 0.28; 1.0	0.61; 0.22; 1.0	0.5; 0.0; 0.0	0.56; 0.12; 1.0	0.58; 0.16; 1.0
0.7, Adagrad, 0.0005	0.96; 0.92; 1.0	0.94; 0.88; 1.0	0.97; 0.94; 1.0	0.9; 0.88; 0.92	0.88; 0.86; 0.9	0.89; 0.82; 0.95	0.73; 0.46; 1.0	0.68; 0.46; 0.82	0.72; 0.46; 0.96	0.52; 0.04; 1.0	0.52; 0.04; 1.0	0.51; 0.04; 0.67
0.7, Adagrad, 0.0001	0.96; 0.94; 0.98	0.92; 0.9; 0.94	0.95; 0.9; 1.0	0.87; 0.84; 0.89	0.84; 0.92; 0.79	0.87; 0.86; 0.88	0.61; 0.28; 0.82	0.55; 0.36; 0.58	0.65; 0.4; 0.8	0.58; 0.92; 0.55	0.58; 0.32; 0.67	0.7; 0.68; 0.71
0.7, Adagrad, 0.001	0.93; 0.86; 1.0	0.95; 0.9; 1.0	0.96; 0.92; 1.0	0.9; 0.86; 0.93	0.86; 0.76; 0.95	0.87; 0.78; 0.95	0.69; 0.38; 1.0	0.65; 0.3; 1.0	0.64; 0.28; 1.0	0.5; 0.0; 0.0	0.51; 0.02; 1.0	0.5; 0.0; 0.0


Priedas nr. 2

Modelio derinimo grafikai


Kiekvienas paveikslukas parodo modelio derinimo tikslumą arba nuostolį. Derinti buvo negilus ir gilus modeliai - NASNetMobile ir NASNetLarge, su gyvūnų ir kambarių duomenų rinkiniais keičiant mokomų sluoksnių skaičių - 5, 10 ir 20.



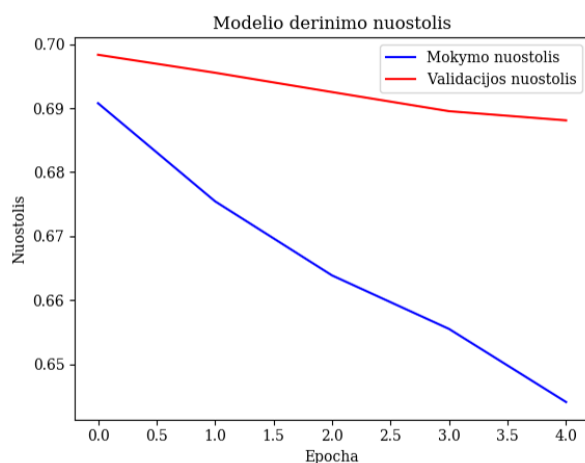
15 pav. NASNetMobile modelio derinimo tikslumas su gyvūnų rinkiniu ir 5 mokymosi sluoksniais




16 pav. NASNetMobile modelio derinimo nuostolis su gyvūnų rinkiniu ir 5 mokymosi sluoksniais




17 pav. NASNetMobile modelio derinimo tikslumas su kambarių rinkiniu ir 5 mokymosi sluoksniais




18 pav. NASNetMobile modelio derinimo nuostolis su kambarių rinkiniu ir 5 mokymosi sluoksniais




19 pav. NASNetMobile modelio derinimo tikslumas su gyvūnų rinkiniu ir 10 mokymosi sluoksnių




20 pav. NASNetMobile modelio derinimo nuostolis su gyvūnų rinkiniu ir 10 mokymosi sluoksnių




21 pav. NASNetMobile modelio derinimo tikslumas su kambarių rinkiniu ir 10 mokymosi sluoksnių




22 pav. NASNetMobile modelio derinimo nuostolis su kambarių rinkiniu ir 10 mokymosi sluoksnių




23 pav. NASNetMobile modelio derinimo tikslumas su gyvūnų rinkiniu ir 20 mokymosi sluoksnių




24 pav. NASNetMobile modelio derinimo nuostolis su gyvūnų rinkiniu ir 20 mokymosi sluoksnių




25 pav. NASNetMobile modelio derinimo tikslumas su kambarių rinkiniu ir 20 mokymosi sluoksnių




26 pav. NASNetMobile modelio derinimo nuostolis su kambarių rinkiniu ir 20 mokymosi sluoksnių




27 pav. NASNetLarge modelio derinimo tikslumas su gyvūnų rinkiniu ir 5 mokymosi sluoksniais




28 pav. NASNetLarge modelio derinimo nuostolis su gyvūnų rinkiniu ir 5 mokymosi sluoksniais




29 pav. NASNetLarge modelio derinimo tikslumas su kambarių rinkiniu ir 5 mokymosi sluoksniais




30 pav. NASNetLarge modelio derinimo nuostolis su kambarių rinkiniu ir 5 mokymosi sluoksniais




31 pav. NASNetLarge modelio derinimo tikslumas su gyvūnų rinkiniu ir 10 mokymosi sluoksnių




32 pav. NASNetLarge modelio derinimo nuostolis su gyvūnų rinkiniu ir 10 mokymosi sluoksnių




33 pav. NASNetLarge modelio derinimo tikslumas su kambarių rinkiniu ir 10 mokymosi sluoksnių




34 pav. NASNetLarge modelio derinimo nuostolis su kambarių rinkiniu ir 10 mokymosi sluoksnių




35 pav. NASNetLarge modelio derinimo tikslumas su gyvūnų rinkiniu ir 20 mokymosi sluoksnių



36 pav. NASNetLarge modelio derinimo nuostolis su gyvūnų rinkiniu ir 20 mokymosi sluoksnių



37 pav. NASNetLarge modelio derinimo tikslumas su kambarių rinkiniu ir 20 mokymosi sluoksnių



38 pav. NASNetLarge modelio derinimo nuostolis su kambarių rinkiniu ir 20 mokymosi sluoksnių